Phân Loại Chọn Lọc và Hiệu Chuẩn Xác Suất Nhằm Nhận Diện Căng Thẳng Đáng Tin Cậy Từ Tín Hiệu Sinh Lý Đeo Cổ Tay

Phan Tuấn Đạt, Nguyễn Gia Huy, Trần Lợi Kiều Nhi, Nguyễn Minh Bảo
Bộ môn Trí tuệ Nhân tạo, Trường Đại học FPT
Email: ptundatwork@gmail.com, huy522006@gmail.com, nhiklt2006@gmail.com, baonguyenminh17@gmail.com

***Tóm tắt nội dung*—Các hệ thống theo dõi căng thẳng tâm lý liên tục qua thiết bị đeo cổ tay mở ra tiềm năng lớn trong chăm sóc sức khỏe chủ động. Tuy nhiên, cảm biến quang học thể tích sóng mạch (BVP) và dẫn truyền da (EDA) đặt tại cổ tay rất nhạy cảm với nhiễu động học. Những cử động tay tự nhiên, cử chỉ và dịch chuyển tư thế thường ngày gây biến dạng tín hiệu rất giống với phản ứng sinh lý khi căng thẳng tâm lý thực sự. Khi bị ép buộc phải đưa ra kết luận nhị phân trên 100% các cửa sổ thời gian (Full Coverage), các mô hình học máy truyền thống tạo ra tỷ lệ báo động giả rất cao khi người dùng cử động, dẫn tới hiện tượng mệt mỏi vì chuông báo động (alarm fatigue) trong thực tế lâm sàng. Bài báo này đề xuất một khung nhận diện căng thẳng đáng tin cậy (Trustworthy AI), kết hợp thuật toán hiệu chuẩn xác suất hồi quy Isotonic với cơ chế phân loại chọn lọc (Selective Classification) tích hợp bối cảnh động học gia tốc trên bộ dữ liệu chuẩn WESAD ($N = 15$). Cơ chế này cho phép mô hình từ chối đưa ra phán đoán (gán nhãn *Bất định / Uncertain*) khi độ tin cậy hậu nghiệm không đạt ngưỡng an toàn $\tau = 0,80$. Thực nghiệm đối đầu trên tám kiến trúc mô hình (bảy mô hình học máy dạng bảng và một mạng nơ-ron sâu MLP) dưới giao thức kiểm định nghiêm ngặt 15-fold Leave-One-Subject-Out (LOSO) kết hợp phân tầng nhóm đối tượng bên trong (GroupKFold) chứng minh rằng: lỗ hổng báo động giả khi vận động là vấn đề phổ biến trên mọi họ thuật toán ($\text{FAR}_{\text{motion}} \approx 12,2\% - 24,0\%$). Quy tắc từ chối đề xuất triệt tiêu từ 55,0% đến 90,0% các báo động giả này, đồng thời nâng cao điểm Macro F_1 thêm từ +3,6 đến +8,2 điểm phần trăm trên tập dữ liệu giữ lại. Tại ngưỡng tin cậy vận hành $\tau = 0,80$ với mô hình XGBoost, hệ thống đạt điểm Selective Macro F_1 gộp là 95,20% (trung bình theo đối tượng: $89,8\% \pm 17,6\%$) và điểm Stress F_1 gộp là 93,15% (trung bình theo đối tượng: $83,1\% \pm 32,6\%$, 95% CI: [84,80%, 98,54%]), với sai số hiệu chuẩn ECE 0,0290 trên tập dữ liệu được giữ lại (không so sánh trực tiếp được với ECE ở độ bao phủ đầy đủ), và giới hạn tỷ lệ báo động giả khi vận động $\text{FAR}_{\text{motion}}$ chỉ còn 4,07% trong khi vẫn duy trì độ bao phủ vận hành thực tế đạt $69,42\%$ (trung bình theo đối tượng: $69,6\% \pm 22,2\%$). Các so sánh với cổng cơ học và từ chối ngẫu nhiên, cùng giải thích TreeSHAP, hỗ trợ khung đề xuất; mức cải thiện nhờ đặc trưng gia tốc và chênh lệch MLP–XGBoost không có ý nghĩa thống kê, và tập dữ liệu phòng lab $N = 15$ hạn chế khả năng khái quát hóa.**

***Index Terms*—Nhận diện Căng thẳng, Thiết bị Đeo Cổ tay, Bộ Dữ liệu WESAD, Phân loại Chọn lọc, Hiệu chuẩn Xác suất, Empatica E4, Báo động Giả do Vận động, Trí tuệ Nhân tạo Đáng tin cậy, Kiểm định LOSO.**

I. Giới thiệu

Căng thẳng tâm lý mãn tính (chronic stress) là một trong những yếu tố nguy cơ hàng đầu gây suy giảm miễn dịch, rối loạn chuyển hóa và các bệnh lý tim mạch nguy hiểm [1]–[3]. Sự phát triển mạnh mẽ của các thiết bị đeo thông minh thương mại mở ra cơ hội theo dõi sinh lý liên tục, không xâm lấn trong đời sống hàng ngày [4]–[6].

Tuy nhiên, rào cản kỹ thuật lớn nhất khi triển khai các hệ thống này trong môi trường tự do chính là *hiện tượng báo động giả do vận động cơ học* (motion-induced false alarms) [7]–[9]. Cử động tay, cử chỉ và dịch chuyển vị trí cảm biến làm biến dạng hình thái sóng quang học BVP và thay đổi tiếp xúc điện cực EDA [10]. Trong môi trường tự nhiên, các biến dạng tín hiệu này biểu hiện rất giống với kích hoạt hệ thần kinh giao cảm do căng thẳng tâm lý thật.

Trong các nghiên cứu trước đây trên bộ dữ liệu chuẩn WESAD [5], [12]–[14], mô hình thường được đánh giá dưới cơ chế phán đoán bắt buộc 100% (Full Coverage). Khi người đeo cử động tay hoặc thay đổi tư thế, các bộ phân loại hiện đại thường hiệu chuẩn kém và có thể dự đoán sai với độ tự tin thái quá [16]; chúng tôi giả thuyết rằng nhiễu vận động làm tình trạng này nghiêm trọng hơn. Báo động giả dày đặc có thể góp phần gây ra hiện tượng mệt mỏi vì chuông báo động (alarm fatigue) [17], khiến người dùng mất niềm tin và tắt thiết bị theo dõi.

Để giải quyết thách thức này, nghiên cứu của chúng tôi tiếp cận bài toán theo nguyên lý **Học máy Đáng tin cậy (Trustworthy AI)**: thay vì ép buộc mô hình phải đoán bừa trên mọi cửa sổ dữ liệu, hệ thống cần lượng hóa độ bất định và từ chối phán đoán (Abstention) khi tín hiệu bị nhiễu hoặc nằm trong vùng mơ hồ thông qua phân loại chọn lọc (Selective Classification) [18]–[23].

A. Các Câu hỏi Nghiên cứu (Research Questions - RQs)

Nghiên cứu được định hướng giải quyết bốn câu hỏi khoa học trọng tâm:

- **RQ1 (Tính nhạy cảm với chuyển động đa kiến trúc):** Hiện tượng báo động giả do vận động có tồn tại dai dẳng trên các họ thuật toán học máy khác nhau khi ép buộc phán đoán 100% hay không?
- **RQ2 (Độ tin cậy trong Phân loại Chọn lọc):** Cơ chế hiệu chuẩn xác suất kết hợp phân loại chọn lọc có thể triệt tiêu báo động giả do vận động đồng thời bảo toàn độ bao phủ vận hành cao hay không?

- **RQ3 (Học máy dạng bảng vs Học sâu):** Các mô hình cây đối đầu với mạng nơ-ron sâu (MLP) như thế nào trên không gian đặc trưng sinh lý chuẩn hóa dưới giao thức LOSO?
- **RQ4 (Động lực học đặc trưng, Bối cảnh động học và Khái quát hóa ca ngoại lai):** Những tương quan đặc trưng sinh lý và động học nào kích hoạt cơ chế từ chối, và hệ thống phản ứng ra sao trước những cá nhân có phản ứng sinh lý không điển hình?

B. Đóng góp Khoa học Chính

Bài báo mang lại bốn đóng góp khoa học cụ thể:

1) **Hình thức hóa và Định lượng Lỗ hổng Vận động ($\mathbf{FAR_{motion}}$):** Chúng tôi định nghĩa chỉ số $\text{FAR}_{\text{motion}}$ trên tập hợp các cửa sổ vận động không stress ($N = 295$ cửa sổ) và khảo sát toàn diện tám thuật toán (bảy mô hình bảng và một mạng MLP) dưới giao thức 15-fold Leave-One-Subject-Out (LOSO) [24], [25]. Kết quả ghi nhận tỷ lệ báo động giả cao trên các cửa sổ vận động mạnh ở mọi họ mô hình ($\text{FAR}_{\text{motion}} \approx 12,2\% - 24,0\%$) khi ép buộc phán đoán 100%. Đối chiếu với cửa sổ ít vận động, tỷ lệ dương tính giả thấp hơn ở mô hình đã hiệu chuẩn Isotonic ($4,4\%$ so với $10,8\%$) nhưng chỉ chênh nhẹ ở XGBoost thô ($10,2\%$ so với $12,2\%$).
2) **Quy trình Hiệu chuẩn Xác suất Hai cấp Chống Rò rỉ Dữ liệu:** Thiết kế đường ống hiệu chuẩn hồi quy Isotonic lồng ghép bên trong phân tầng nhóm đối tượng (`GroupKFold`, 3 inner folds). Quy trình này được thiết kế để tránh thiên lệch lạc quan do cửa sổ trượt gối đầu 91,7%; các dự đoán được giữ lại đạt ECE = **0,0290** (ECE theo độ tin cậy, chỉ tính trên vùng được giữ lại nên không so sánh trực tiếp với ECE ở độ bao phủ đầy đủ).
3) **Khung Phân loại Chọn lọc Tích hợp Bối cảnh Động học Gia tốc:** Xây dựng quy tắc từ chối dựa trên ngưỡng tin cậy $\tau = 0,80$ tích hợp 6 đặc trưng gia tốc kế (ACC). Khung giải pháp triệt tiêu từ 55,0% đến 90,0% báo động giả do vận động trên cả tám mô hình, giúp XGBoost đạt Selective Macro F_1 là **95,20%** tại độ bao phủ $69,42\%$, (phân tích 5 seed chỉ áp dụng cho ablation gia tốc và MLP; mức cải thiện nhờ gia tốc không có ý nghĩa thống kê).
4) **Giải thích Y sinh XAI và Phân tích Thực nghiệm Dạng bảng vs Học sâu:** Ứng dụng TreeSHAP [26] lượng hóa đóng góp của 4 kênh cảm biến, làm rõ mẫu hình xung đột tín hiệu kích hoạt từ chối phán đoán, và phân tích sâu ca ngoại lai giảm phản ứng điện da (Subject S14).

II. Tổng quan nghiên cứu & Khoảng trống khoa học

A. Nhận diện Căng thẳng Qua Thiết bị Đeo Cổ tay

Các nghiên cứu ban đầu tập trung vào dây đeo ngực hoặc điện tâm đồ đa đạo trình (ECG) [27]. Với sự xuất hiện của các thiết bị đeo tay y tế đa cảm biến như Empatica E3 và E4 [28], [42], các công trình gần đây chuyển dịch mạnh mẽ sang khai thác BVP, EDA, nhiệt độ da (TEMP) và gia tốc (ACC) [3], [4].

Schmidt cùng cộng sự [5] công bố bộ dữ liệu chuẩn WESAD ($N = 15$), chỉ ra rằng việc nhận diện stress từ cổ tay khó khăn hơn nhiều so với ngực do cổ tay cử động tự do, báo cáo độ chính xác nhị phân 87,12% ($F_1 = 84,11\%$) với mô hình Random Forest trên dữ liệu cổ tay. Bobade và Vani [12] khảo sát các mô hình truyền thống và học sâu CNN/LSTM; tuy nhiên, theo chúng tôi hiểu, quy trình đánh giá không độc lập theo đối tượng, có thể gây rò rỉ dữ liệu giữa các cửa sổ trượt liền kề. Siirtola [11] nghiên cứu nhận diện căng thẳng liên tục bằng các cảm biến của smartwatch thương mại. Sano et al. [6] nghiên cứu nhận diện mức căng thẳng từ dữ liệu cảm biến đeo và điện thoại trong đời sống hằng ngày. Gjoreski et al. [41] dùng thông tin ngữ cảnh (hoạt động) với thiết bị cổ tay để cải thiện theo dõi căng thẳng, là công trình sử dụng ngữ cảnh động học gần nhất. Gần đây, Behinaein et al. [14] và Dalmeida và Masala [13] nghiên cứu các kiến trúc transformer trên ECG và HRV, tuy nhiên việc triển khai các mô hình này trên phần cứng nhúng vẫn là mối quan ngại thực tế.

B. Nhiễu Động học và Báo động Giả

Chuyển động tay làm biến dạng sóng quang học BVP và làm xê dịch điện cực đo EDA [7]–[9], [43]–[45]. Các phương pháp lọc số (Butterworth) hoặc triệt nhiễu thích nghi [9] giúp làm giảm nhiễu điện cao tần, nhưng không thể phân biệt được các đáp ứng sinh lý thực khi nhiễu cơ học gối chồng lên dải tần nhịp tim và dẫn truyền da. Khi mô hình bị ép buộc phán đoán 100%, tỷ lệ báo động giả khi vận động luôn ở mức cao, dẫn tới hiện tượng mệt mỏi vì chuông báo [17].

C. Phân loại Chọn lọc và Học có Từ chối

Bắt nguồn từ nền tảng của Chow [18], học có từ chối (learning with rejection) cho phép bộ phân loại bảo lưu ý kiến khi chi phí phán đoán sai lớn hơn chi phí từ chối. El-Yaniv và Wiener [39] hình thức hóa sự đánh đổi rủi ro - độ bao phủ (Risk-Coverage) của phân loại chọn lọc, và Geifman và El-Yaniv [20], [21] mở rộng cho mạng nơ-ron sâu. Các công trình lý thuyết của Cortes et al. [19], Grandvalet et al. [22], và khảo sát của Hendrickx et al. [23] đã khẳng định giá trị của cơ chế từ chối trong các bài toán nhạy cảm với rủi ro. Chúng tôi chưa biết công trình nào áp dụng có hệ thống phân loại chọn lọc cho báo động giả do cử động tay trên thiết bị đeo; tuy nhiên chúng tôi chưa thực hiện tổng quan hệ thống đầy đủ, và các hướng tiếp cận có xét ngữ cảnh đã tồn tại [41].

D. Hiệu chuẩn Xác suất và Rò rỉ Dữ liệu Cửa sổ Trượt

Phân loại chọn lọc đòi hỏi xác suất hậu nghiệm phải được hiệu chuẩn chuẩn xác: độ tự tin dự đoán phải phản ánh đúng tần suất chính xác thực nghiệm [16], [40]. Các kỹ thuật hậu xử lý phổ biến gồm Platt scaling (Sigmoid) [29], Beta calibration [30], và hồi quy Isotonic phi tham số [31], [32].

Trong chuỗi thời gian sinh lý, cửa sổ trượt 60 giây (bước nhảy 5 giây) tạo ra độ gối đầu tới 91,7%. Nếu chia dữ liệu ngẫu nhiên, các cửa sổ liền kề của cùng một người sẽ lọt vào cả tập huấn luyện và tập hiệu chuẩn, gây ra ảo tưởng hiệu chuẩn (optimistic bias) [24], [25]. Chúng tôi giải quyết triệt để vấn đề này bằng thiết kế hai cấp lồng ghép phân tầng theo nhóm đối tượng.

E. Lý do Ưu tiên Học máy Dạng bảng

Việc ưu tiên các mô hình cây quyết định (Random Forest, LightGBM, XGBoost [33]) dựa trên ba căn cứ:

1) **Quy mô Mẫu ($N = 15$ Đối tượng):** Các công trình của Shwartz-Ziv và Armon [34], Grinsztajn et al. [35], và Borisov et al. [36] chứng minh rằng trên dữ liệu dạng bảng quy mô vừa và nhỏ, mô hình cây thường vượt trội hoặc ngang ngửa học sâu. Mạng nơ-ron dung lượng lớn rất dễ overfit vào đặc điểm sinh lý cá nhân của số ít đối tượng.
2) **Khả năng Giải thích Y sinh (XAI):** Các đặc trưng HRV và EDA (RMSSD, LF/HF, đỉnh SCR) gắn liền với sinh lý học thần kinh tự chủ [10], [27], [37], [38]. Khi kết hợp với TreeSHAP [26], mô hình cây cho phép bóc tách tường minh lý do đưa ra cảnh báo hoặc từ chối phán đoán.
3) **Khả thi trên Phần cứng Nhúng Cổ tay:** Thiết bị đeo thương mại vận hành dưới giới hạn năng lượng vi điều khiển khắt khe. Mô hình cây kết hợp bảng tra cứu Isotonic tiêu tốn cực ít bộ nhớ và chi phí suy luận $O(T \cdot \text{depth})$ cho tập hợp T cây, nhờ đó thuận lợi cho triển khai trên chip (chưa được đo trên phần cứng trong nghiên cứu này).

Để đối chứng khách quan, chúng tôi huấn luyện thêm một mô hình mạng nơ-ron sâu MLP trên cùng không gian 25 đặc trưng chuẩn hóa dưới cùng điều kiện 15-fold LOSO. Bảng I tóm tắt sự khác biệt giữa nghiên cứu này và các công trình liên quan.

III. Phương pháp đề xuất

A. Quy trình Tiền xử lý & Trích xuất Đặc trưng

Dữ liệu liên tục từ vòng đeo tay Empatica E4 được phân đoạn thành các cửa sổ trượt $W = 60\,\text{s}$ với bước nhảy $\Delta t = 5\,\text{s}$ (độ gối đầu 91,7%). Mặc dù khuyến nghị Task Force tiêu chuẩn yêu cầu 5 phút cho phân tích HRV thông thường [27], cửa sổ 60 giây thuộc nhóm HRV siêu ngắn hạn (Ultra-Short-Term HRV - UST-HRV), trong đó các đặc trưng miền thời gian (Mean HR, RMSSD) giữ được độ tin cậy cao trong khi các đặc trưng tần số (LF, LF/HF) cần được diễn giải cẩn trọng [47], [48]. Biến đổi HRV khi căng thẳng tâm lý cấp tính được tổng hợp trong [15]; ngoài ra HRV suy ra từ BVP cổ tay thực chất là biến thiên nhịp mạch (PRV), một đại lượng thay thế cho HRV từ ECG [46]:

- **Tín hiệu BVP (64 Hz):** Làm sạch bằng quy trình PPG của NeuroKit2 (lọc dải thông xấp xỉ 0,5–8,0 Hz) [37]. Dò tìm các đỉnh tâm thu để xác định chuỗi khoảng cách giữa hai nhịp tim liên tiếp (IBI). Loại bỏ các khoảng IBI nhiễu ngoài dải 300–1800 ms, sau đó nội suy spline bậc ba về tần số 4 Hz [38]. Các đặc trưng trích xuất gồm miền thời gian (Mean HR, SDNN, RMSSD, pNN50) và miền tần số qua phương pháp Welch [49]: công suất tần số thấp LF (0,04–0,15 Hz), tần số cao HF (0,15–0,40 Hz), và tỷ số cân bằng giao cảm/phó giao cảm LF/HF.
- **Tín hiệu EDA (4 Hz):** Phân tách bằng phương pháp lọc thông cao tiêu chuẩn trong NeuroKit2 [10], [37] thành thành phần trương lực (tonic SCL) và thành phần pha (phasic SCR). Trích xuất số lượng đỉnh SCR, biên độ đỉnh cực đại, giá trị trung bình và độ lệch chuẩn của cả tonic và phasic, cùng năng lượng pha $\sum \text{Phasic}^2$ [10].
- **Tín hiệu TEMP (4 Hz):** Nhiệt độ bề mặt da phản ánh sự co mạch ngoại vi. Trích xuất giá trị trung bình, độ lệch chuẩn, các cực trị min/max, và hệ số góc hồi quy tuyến tính.
- **Tín hiệu ACC (32 Hz):** Cảm biến gia tốc ba trục trên E4 ghi nhận tín hiệu theo đơn vị $1/64\,g$. Gia tốc ba trục được tính độ lớn vector Euclidean $a(t) = \sqrt{a_x^2(t) + a_y^2(t) + a_z^2(t)}$. Trích xuất đủ 6 đặc trưng: giá trị trung bình, độ lệch chuẩn, phương sai Var(ACC) (theo đơn vị $(1/64\,g)^2$, đại diện cho cường độ cử động tay), giá trị đỉnh cực đại, tỷ lệ qua điểm không (ZCR), và năng lượng phổ tín hiệu.

Tập dữ liệu hoàn chỉnh gồm 5.294 cửa sổ quan sát trên toàn bộ 15 đối tượng hợp lệ của WESAD ($S2, S3, \ldots, S17$; trong đó $S1$ và $S12$ bị lỗi phần cứng cảm biến đã được loại bỏ từ đầu [5]). Không gian đặc trưng chuẩn hóa gồm đúng 25 đặc trưng liên tục. Chỉ dùng hai pha Baseline (Không Stress) và TSST Stress; các pha Amusement và Meditation bị loại, và một cửa sổ chỉ được giữ nếu ít nhất 80% mẫu cùng một nhãn. Giá trị đặc trưng bị thiếu (ví dụ cửa sổ có quá ít nhịp được phát hiện) được điền không dùng nhãn bằng trung vị theo từng đối tượng, sau đó bằng trung vị toàn cục. Do đó lớp Không Stress chính là trạng thái ngồi nghỉ ở pha baseline chứ không phải hoạt động đời thường bất kỳ.

B. Hiệu chuẩn Xác suất Hậu nghiệm

Gọi $x \in \mathbb{R}^d$ là vector đặc trưng và $y \in \{0, 1\}$ là nhãn thực tế (0: Không Stress, 1: Căng thẳng). Đầu ra thô $f(x)$ của mô hình được chuyển đổi thành xác suất hiệu chuẩn qua hàm hồi quy Isotonic đơn điệu [31], [32]:

$$\hat{P}(Y = 1|x) = g(f(x)) \tag{1}$$

trong đó $g(\cdot)$ tối thiểu hóa hàm mất mát bình phương dưới ràng buộc đơn điệu:

$$\begin{aligned} &\min_{g} \sum_{i=1}^{N_{\text{cal}}} \left(y_i - g(f(x_i))\right)^2 \\ &\text{s.t. } g(f(x_i)) \le g(f(x_j)) \quad \forall\, f(x_i) \le f(x_j) \end{aligned} \tag{2}$$

C. Quy tắc Phán đoán Chọn lọc

Gọi $\hat{p}_1 = \hat{P}(Y = 1|x)$. Chúng tôi thiết lập quy tắc phán đoán an toàn dựa trên ngưỡng tin cậy $\tau \in [0,5; 1,0)$:

$$\hat{y}(x) = \begin{cases} 1 \text{ (Căng thẳng)}, & \text{nếu } \hat{p}_1 \ge \tau \\ 0 \text{ (Bình thường)}, & \text{nếu } \hat{p}_1 \le 1 - \tau \\ \text{Bất định}, & \text{nếu } 1 - \tau < \hat{p}_1 < \tau \end{cases} \tag{3}$$

Khi xác suất hậu nghiệm rơi vào khoảng lưỡng lự $(1 - \tau, \tau)$, hệ thống bảo lưu quyết định (Abstain). Cơ chế này chủ động gạt bỏ các mẫu nằm ở vùng biên phán đoán vốn là nguồn cơn gây ra phần lớn các báo động giả khi người dùng cử động.

Bảng I
SO SÁNH CÁC NGHIÊN CỨU NHẬN DIỆN CĂNG THẲNG QUA THIẾT BỊ ĐEO VÀ PHƯƠNG PHÁP ĐỀ XUẤT.

Công trình	Thiết bị / Vị trí	Dòng Mô hình	Giao thức Đánh giá	Hiệu chuẩn Xác suất	Bối cảnh Động học (ACC)	Cơ chế Từ chối
Schmidt et al. (2018) [5]	E4 (cổ tay) + RespiBAN (ngực)	Random Forest (87,12% Acc)	LOSO (15 folds)	Không	Đặc trưng cơ bản	Không (Ép buộc 100%)
Bobade & Vani (2020) [12]	E4 (cổ tay) + RespiBAN	SVM, KNN, CNN, LSTM	K-Fold Ngẫu nhiên	Không	Đặc trưng cơ bản	Không (Ép buộc 100%)
Siirtola (2019) [11]	Smartwatch (cổ tay - BVP)	Random Forest, QDA	LOSO	Không	Không đưa vào	Không (Ép buộc 100%)
Gjoreski et al. (2016) [4]	Thiết bị cổ tay	Random Forest, Ensemble	Phòng lab & Đời thực	Không	Lọc hoạt động thô	Không (Ép buộc 100%)
Can et al. (2019) [3]	Thiết bị đeo đa cảm biến	Khảo sát tổng quan	Đa giao thức	Không	Phân tích khảo sát	Không (Ép buộc 100%)
Behinaein et al. (2021) [14]	Thiết bị đeo ECG	Transformer, Học sâu	LOSO	Không	Không đưa vào	Không (Ép buộc 100%)
Nghiên cứu Đề xuất	**Empatica E4 (cổ tay)**	**8 Mô hình (7 Dạng bảng + MLP)**	**LOSO Hai cấp 15-folds**	**Có (Inner GroupKFold Isotonic)**	**Tích hợp 6 Đặc trưng ACC**	**Có (Quy tắc Chọn lọc $\tau = 0,80$)**

IV. THIẾT LẬP THỰC NGHIỆM

A. Giao thức Kiểm định Nghiêm ngặt LOSO Hai cấp

Để đánh giá khả năng tổng quát hóa trên người chưa từng xuất hiện trong tập huấn luyện, chúng tôi triển khai giao thức 15-fold Leave-One-Subject-Out (LOSO). Ở mỗi fold $k \in \{1, \ldots, 15\}$, toàn bộ dữ liệu của một đối tượng S_k được tách riêng làm tập kiểm thử $\mathcal{D}_{\text{test}}^{(k)}$.

Để hiệu chuẩn xác suất mà không làm rò rỉ dữ liệu, 14 đối tượng còn lại $\mathcal{D}_{\text{train}}^{(k)}$ được chia tiếp bằng kiểm định chéo nội bộ 3-fold `GroupKFold` phân tầng chặt chẽ theo `subject_id`. Theo cài đặt `CalibratedClassifierCV` của scikit-learn [55], ở mỗi fold trong, bộ phân loại được huấn luyện trên các đối tượng huấn luyện nội bộ và điểm của nó trên các đối tượng giữ lại nội bộ được dùng để huấn luyện bộ hiệu chuẩn Isotonic $g^{(k)}$; xác suất cuối cùng là trung bình của ba mô hình đã hiệu chuẩn. Sau đó, toàn bộ đường ống đã hiệu chuẩn mới được áp dụng lên đối tượng kiểm thử độc lập $\mathcal{D}_{\text{test}}^{(k)}$.

B. Tập Mô hình Khảo sát (7 Dạng bảng + 1 Học sâu MLP)

Tám thuật toán đại diện cho các trường phái học máy khác nhau được đưa vào khảo sát:

1) **Logistic Regression (LR):** Mô hình tuyến tính với điều chuẩn L2 (max_iter $= 500$).
2) **Decision Tree (CART):** Cây quyết định đơn lẻ [59] với max_depth $= 5$.
3) **k-Nearest Neighbors (kNN):** Phân loại láng giềng gần nhất [60] ($k = 5$).
4) **AdaBoost:** Tăng cường tương thích [58] với 50 gốc cây quyết định.
5) **Random Forest (RF):** Rừng ngẫu nhiên [57] gồm 100 cây (max_depth $= 5$).
6) **LightGBM:** Gradient boosting [56] (100 cây, max_depth $= 5$, learning_rate $= 0,08$).
7) **MLP (Học sâu):** Mạng Perceptron đa tầng (kiến trúc: 25–64–32–1 với một đầu ra logit, 3.777 tham số, kích hoạt ReLU, dropout 0,2, tối ưu Adam [61], tốc độ học 10^{-3}, suy giảm trọng số 10^{-4}, dừng sớm dựa trên tập validation nội bộ để chống rò rỉ; kết quả lấy trung bình 5 seed và được hiệu chuẩn bằng temperature scaling hoặc Isotonic như ghi chú).
8) **XGBoost (Đề xuất):** Gradient boosting (100 cây, max_depth $= 5$, tốc độ học $0,08$, lấy mẫu dòng $0,8$; tham số lấy mẫu cột giữ mặc định $1,0$).

C. Chỉ số Đánh giá và Khoảng Tin cậy Bootstrap

Hiệu năng được đo lường bằng Macro F_1, F_1 của lớp Căng thẳng (Stress), và Độ bao phủ hữu dụng (Usable Coverage):

$$\text{Coverage} = \frac{|\{x \in \mathcal{D}_{\text{test}} : \hat{y}(x) \neq \text{Bất định}\}|}{|\mathcal{D}_{\text{test}}|} \tag{4}$$

Sai số hiệu chuẩn kỳ vọng ECE [40] được tính trên độ tin cậy $\max(\hat{p}_1, 1-\hat{p}_1) \in [0,5; 1]$ với $M = 10$ khoảng bằng nhau, trong đó $\text{acc}(B_m)$ và $\text{conf}(B_m)$ là độ chính xác và độ tin cậy trung bình trong khoảng B_m:

$$\text{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N} \left|\text{acc}(B_m) - \text{conf}(B_m)\right| \tag{5}$$

So sánh thống kê được thực hiện bằng kiểm định cặp Wilcoxon signed-rank [50] kèm hiệu chỉnh Holm–Bonferroni [51], [52] (p_{holm}) và hệ số tương quan hạng-nhị phân cặp r_{rb} [53]. Khoảng tin cậy 95% được ước tính qua phương pháp Bootstrap [54] theo cụm đối tượng với $B = 1.000$ lần lặp lại. Với $\tau = 0,80$, các dự đoán được giữ lại thỏa $\hat{p}_1 \leq 0,2$ hoặc $\geq 0,8$ nên ECE trên tập giữ lại chỉ phủ các khoảng $[0,8; 1,0]$ và không so sánh trực tiếp được với ECE ở độ bao phủ đầy đủ. Trừ khi nêu khác, kết quả dùng một seed (42); MLP và ablation dùng 5 seed (42, 123, 456, 789, 2024).

D. Chỉ số Báo động Giả khi Vận động (FAR_{motion})

Để đo lường tỷ lệ báo động giả khi có cử động tay, gọi $\mathcal{M}_{\text{test}} = \{x \in \mathcal{D}_{\text{test}} \mid y = 0,\ \text{Var(ACC)} \geq \theta_{\text{motion}}\}$ là tập hợp các cửa sổ bình thường (không căng thẳng) nhưng có vận động tay mạnh ($N = 295$ cửa sổ). Ngưỡng $\theta_{\text{motion}} = 15,385$ là phân vị thứ 80 của phương sai gia tốc trên toàn bộ tập dữ liệu WESAD (1.059/5.294 cửa sổ), cô lập nhóm 20% các cửa sổ có cử động tay rõ rệt nhất. Vì việc từ chối phán đoán (Abstain) không phát ra chuông cảnh báo nên không bị coi là báo động giả, chỉ số $\text{FAR}_{\text{motion}}$ được tính trên mẫu số toàn bộ 295 cửa sổ chuyển động:

$$\text{FAR}_{\text{motion}} = \frac{|\{x \in \mathcal{M}_{\text{test}} : \hat{y}(x) = 1\}|}{|\mathcal{M}_{\text{test}}|} \tag{6}$$

V. KẾT QUẢ THỰC NGHIỆM VÀ THẢO LUẬN

A. Khảo sát Đa Mô hình Benchmark (Trả lời RQ1)

Bảng II tóm tắt hiệu năng của cả tám mô hình dưới hai chế độ: bắt buộc phán đoán 100% và phân loại chọn lọc ($\tau = 0,80$).

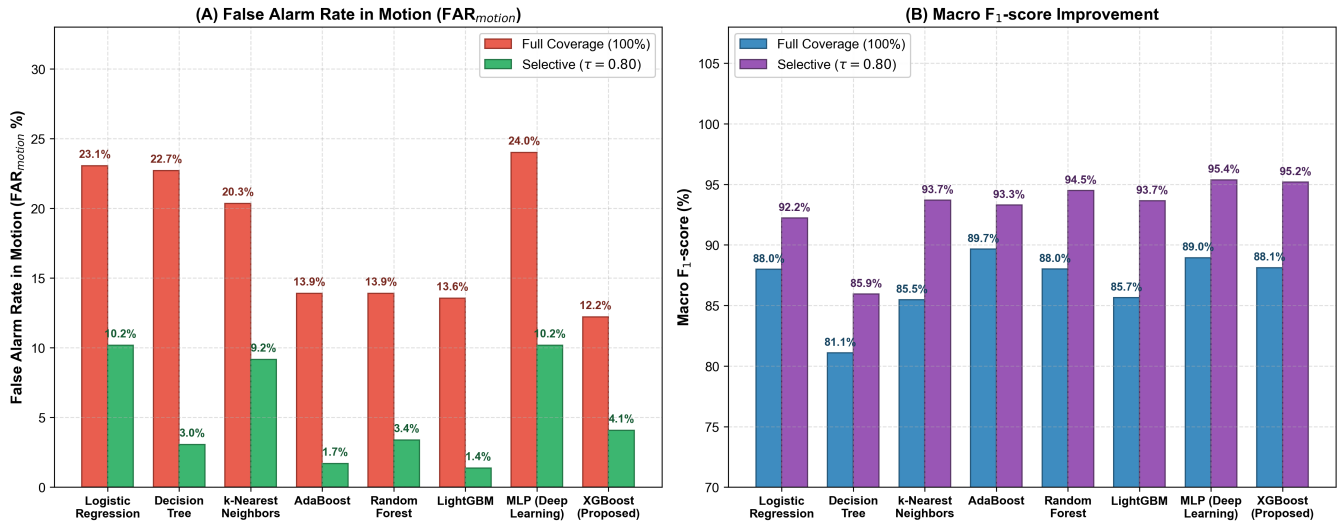
Kết quả benchmark chỉ ra hai phát hiện cốt lõi:

1) **Lỗ hổng Báo động Giả Phổ biến:** Dưới chế độ bắt buộc phán đoán 100%, tất cả các mô hình đều ghi nhận tỷ lệ

Bảng II

HIỆU NĂNG ĐỐI ĐẦU GIỮA TÁM KIẾN TRÚC MÔ HÌNH (BẢY MÔ HÌNH DẠNG BẢNG VÀ MỘT MẠNG SÂU MLP) DƯỚI KIỂM ĐỊNH 15-FOLD LEAVE-ONE-SUBJECT-OUT (LOSO) TRÊN BỘ DỮ LIỆU WESAD. †CÁC DÒNG MLP LÀ TRUNG BÌNH 5 SEED (MÔ HÌNH KHÁC: SEED 42), VÀ CỘT "BẮT BUỘC TOÀN PHẦN" CỦA MLP DÙNG ĐẦU RA ĐÃ TEMPERATURE SCALING (MLP THÔ: MACRO F_1 88,49%, FAR_{MOT} 21,69%). ECE CHỌN LỌC CHỈ TÍNH TRÊN CÁC DỰ ĐOÁN ĐƯỢC GIỮ LẠI.

Kiến trúc Mô hình	**Bắt buộc Toàn phần (100%) Thô**				**Đã Hiệu chuẩn Isotonic**		**Phân loại Chọn lọc ($\tau = 0,80$)**				
Giảm FAR	**Độ CX (%)**	**Macro F_1**	**ECE**	FAR_{mot}	**ECE**	FAR_{mot}	**Bao phủ**	**Độ CX (%)**	**Macro F_1**	**ECE**	FAR_{mot}
Schmidt et al. (2018) [5] (RF)	87,12	84,11%	–	–	–	–	100,0%	–	–	–	–
–											
Logistic Regression	88,93	88,00%	0,0460	23,05%	0,0469	24,41%	72,48%	93,54	92,23%	0,0485	10,17%
55,9%											
Decision Tree (CART)	82,43	81,09%	0,1468	22,71%	0,0973	11,86%	50,70%	91,73	85,94%	0,0465	3,05%
86,6%											
k-Nearest Neighbors	86,95	85,48%	0,0835	20,34%	0,0548	20,34%	64,94%	95,03	93,69%	0,0500	9,15%
55,0%											
AdaBoost Classifier	90,52	89,66%	0,2727	13,90%	0,0722	12,88%	77,13%	94,24	93,29%	0,0548	1,69%
87,8%											
Random Forest	89,21	88,01%	0,0638	13,90%	0,0390	16,61%	75,03%	95,32	94,49%	0,0336	3,39%
75,6%											
LightGBM	86,53	85,66%	0,0915	13,56%	0,0686	9,49%	63,15%	95,09	93,65%	0,0333	1,36%
90,0%											
MLP (Học sâu)†	89,63	88,95%	0,0312	24,00%	0,0336	25,63%	75,16%	95,76	95,38%	0,0179	10,17%
57,6%											
XGBoost (Đề xuất)	**88,97**	**88,13%**	**0,0612**	**12,20%**	**0,0744**	**10,85%**	**69,42%**	**96,08**	**95,20%**	**0,0290**	**4,07%**
66,6%											



Hình 1. So sánh hiệu năng đa mô hình trên tám thuật toán: (A) Tỷ lệ báo động giả khi vận động ($\text{FAR}_{\text{motion}}$) được dập tắt từ 55,0% đến 90,0% trên mọi mô hình; (B) Mức tăng trưởng điểm Selective Macro F_1 tại ngưỡng $\tau = 0,80$.

báo động giả khi vận động rất cao: $\text{FAR}_{\text{motion}}$ dao động từ $12,20\%$ (XGBoost) đến $24,00\%$ (MLP đã temperature scaling; $21,69\%$ với MLP thô). Mặc dù MLP đạt điểm tổng thể cạnh tranh ($F_1 = 88,95\%$), mô hình này có tỷ lệ báo động giả khi vận động cao nhất. Chênh lệch vài điểm giữa các mô hình cây ứng với vài cửa sổ trong $N = 295$ (ví dụ $12,20\%$ = 36 cửa sổ so với $13,90\%$ = 41) và chưa có khoảng tin cậy, nên chúng tôi không xếp hạng mô hình theo $\text{FAR}_{\text{motion}}$ thô. Đối chiếu, tỷ lệ dương tính giả trên cửa sổ không stress ít vận động là $10,2\%$ với XGBoost thô so với $12,2\%$ khi vận động, tức mức vượt trội riêng cho vận động của mô hình thô là khiêm tốn; mức này lớn hơn sau hiệu chuẩn Isotonic ($4,4\%$ so với $10,8\%$). Do đó báo động giả tăng cao khi vận động xuất hiện ở nhiều họ thuật toán, dù dữ liệu này chưa tách riêng được vận động như nguyên nhân duy nhất.

2) **Hiệu quả của Phân loại Chọn lọc:** Áp dụng cơ chế chọn lọc tại $\tau = 0,80$ giúp dập tắt mạnh mẽ báo động giả trên **toàn bộ tám kiến trúc** (mức giảm tương đối từ 55,0% đến 90,0%), đồng thời nâng Macro F_1 thêm từ +3,6 đến +8,2 điểm phần trăm trên tập dữ liệu giữ lại (ví dụ kNN tăng +8,21 điểm phần trăm từ 85,48% lên 93,69%). XGBoost đạt điểm cân bằng vận hành hiệu quả: giới hạn $\text{FAR}_{\text{motion}}$ xuống còn $4,07\%$ (giảm $66,6\%$ so với baseline thô ban đầu) và đạt Selective Macro F_1 là 95,20% tại độ bao phủ $69,42\%$. Mặc dù Random Forest có độ bao phủ nhỉnh hơn (75,03%) với FAR tương đương (3,39%), XGBoost được chọn làm mô hình chính vì cân

bằng giữa độ bao phủ và báo động giả cùng khả năng giải thích TreeSHAP chính xác; Random Forest và LightGBM cũng hỗ trợ TreeSHAP, LightGBM có $\text{FAR}_{\text{motion}}$ chọn lọc thấp nhất (1,36%) và MLP có Selective Macro F_1 nhỉnh hơn, nên đây là lựa chọn thiết kế chứ không phải ưu thế có ý nghĩa thống kê. Ngoài ra $\tau = 0,80$ là điểm vận hành minh họa cố định. Khi chọn τ trên dữ liệu validation nội bộ (rủi ro chọn lọc mục tiêu $\leq 5\%$; trung bình 5 seed), XGBoost hiệu chuẩn Isotonic đạt độ bao phủ 48,1%, Selective Macro F_1 96,39% và $\text{FAR}_{\text{motion}}$ 0,68%, so với 78,3%, 93,03% và 3,59% khi áp dụng cùng quy tắc trên điểm XGBoost chưa hiệu chuẩn; điều này gợi ý (nhưng trên một tập dữ liệu chưa chứng minh) rằng hiệu chuẩn hỗ trợ quy tắc từ chối.

B. Học máy Dạng bảng (XGBoost) vs Học sâu (MLP) (Trả lời RQ3)

Kiểm định Wilcoxon signed-rank và khoảng tin cậy bootstrap trên 15 fold LOSO cho thấy:

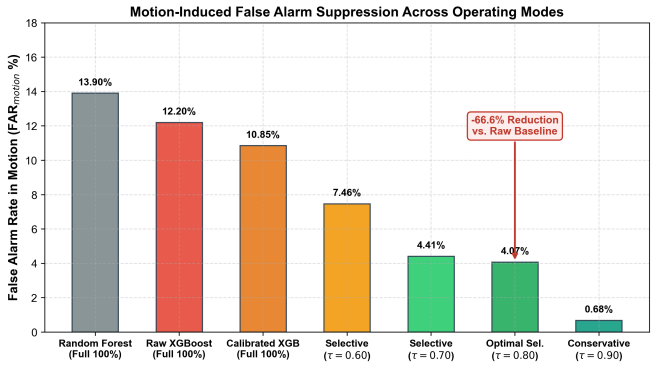
- **So sánh khi Bắt buộc Phán đoán 100%:** Macro F_1 giữa MLP $(88,95\%)$ và XGBoost $(88,13\%)$ không có sự khác biệt mang ý nghĩa thống kê ($W = 52,0, n_{\text{nonzero}} = 14, p = 0,975, r_{rb} = -0,010, p_{\text{holm}} = 1,0$). XGBoost có ước lượng điểm báo động giả khi vận động thấp hơn ($12,20\%$ so với $24,00\%$ của MLP), nhưng số của MLP là trung bình 5 seed của đầu ra đã temperature scaling còn XGBoost dùng seed 42, và chưa có kiểm định ý nghĩa thống kê cho $\text{FAR}_{\text{motion}}$ ở độ bao phủ đầy đủ.
- **Hiệu năng Chọn lọc tại $\tau = 0,80$:** Cả hai mô hình đều vượt mốc 95% Selective Macro F_1 ($95,38\%$ với MLP và $95,20\%$ với XGBoost). Khoảng tin cậy bootstrap cặp theo cụm đối tượng $(MLP - XGB)$ đều chứa số không: $\Delta F_1 = +0,0117$ (95% CI: $[-0,0256; +0,0513]$) và $\Delta\text{FAR}_{\text{sel}} = +2,03\%$ (95% CI: $[-5,44\%; +8,54\%]$), cho thấy chưa phát hiện được khác biệt giữa hai trường phái ở cỡ mẫu này. Các chênh lệch bootstrap này dùng giá trị theo đối tượng đã lấy trung bình 5 seed nên khác với hiệu của các giá trị gộp trong Bảng II.
- **Tính Ổn định Giữa các Đối tượng:** Trên cá nhân S14 (Fold 12), MLP đạt Stress F_1 ở độ bao phủ đầy đủ là $97,2\%$ (lần chạy seed 42) so với $24,7\%$ của XGBoost hiệu chuẩn; chúng tôi giả thuyết MLP dùng các tổ hợp đặc trưng ít phụ thuộc biên độ EDA bị triệt tiêu, nhưng chưa có phân tích nào tách riêng cơ chế này. Với ngưỡng chọn trên validation nội bộ τ^* (seed 42), MLP từ chối mọi cửa sổ của đối tượng S17 (Fold 15; độ bao phủ 0%), trong khi XGBoost ở $\tau = 0,80$ cố định giữ được độ bao phủ trên cả 15 đối tượng (gộp $69,42\%$, trung bình $69,6\% \pm 22,2\%$, thấp nhất $14,8\%$); hai quy tắc ngưỡng không so sánh trực tiếp được.
- **Khía cạnh Phần cứng Thiết bị Đeo:** Dưới góc độ phần cứng nhúng, cả XGBoost và mạng MLP nhỏ (khoảng 3,8 nghìn tham số) được kỳ vọng có chi phí suy luận thấp trên vi điều khiển lớp ARM Cortex-M4/M33; độ trễ trên thiết bị chưa được đo trong nghiên cứu này. Tuy nhiên, mô hình cây có lợi thế diễn giải trực tiếp qua các ngưỡng phân nhánh. Trên thực tế, thời gian thực thi chủ yếu nằm ở khâu trích xuất đặc trưng sinh lý (như lọc số và biến đổi phổ FFT), vốn có thể được lập lịch định kỳ để tiết kiệm pin trên thiết bị đeo.

C. Sự Đánh đổi Chọn lọc và Đánh giá Chi tiết 15 Folds (Trả lời RQ2 & RQ3)

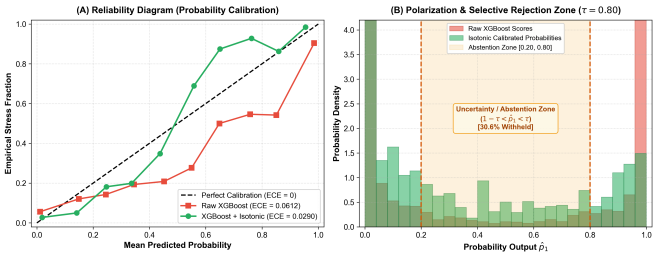
Bảng III thể hiện sự đánh đổi có hệ thống của XGBoost qua các ngưỡng $\tau \in [0,60; 0,90]$. Mức giảm báo động giả được minh họa ở Hình 2, giản đồ tin cậy hiệu chuẩn xác suất ở Hình 3, và đường cong rủi ro - độ bao phủ ở Hình 4.

Bảng III
ĐẶC TÍNH ĐÁNH ĐỔI TRONG PHÂN LOẠI CHỌN LỌC CỦA XGBOOST QUA CÁC NGƯỠNG TIN CẬY τ DƯỚI KIỂM ĐỊNH 15-FOLD LOSO.

Cấu hình	Độ Bao phủ	Macro F_1	Stress F_1	ECE	$\text{FAR}_{\text{motion}}$
XGBoost (Thô Toàn phần 100%)	100,0%	88,13%	84,99%	0,0612	12,20%
XGBoost + Isotonic (100%)	100,0%	89,88%	86,68%	0,0744	10,85%
Chọn lọc ($\tau = 0,60$)	89,76%	92,86%	90,45%	0,0534	7,46%
Chọn lọc ($\tau = 0,70$)	81,79%	93,68%	91,28%	0,0406	4,41%
Chọn lọc Vận hành ($\tau = 0,80$)	**69,42%**	**95,20%**	**93,15%**	**0,0290**	**4,07%**
Chọn lọc Khắt khe ($\tau = 0,90$)	50,38%	96,93%	95,54%	0,0161	0,68%

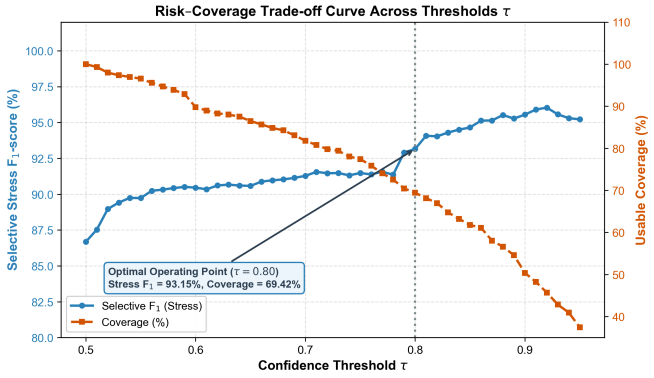


Hình 2. Mức độ dập tắt tỷ lệ báo động giả khi vận động ($\text{FAR}_{\text{motion}}$) từ chế độ bắt buộc sang phân loại chọn lọc.



Hình 3. Giản đồ độ tin cậy: XGBoost trước và sau hiệu chuẩn Isotonic (dự đoán ngoài tập gộp). Hiệu chuẩn Isotonic cải thiện độ khớp với đường chéo ở vùng xác suất trung gian, dù ECE ở độ bao phủ đầy đủ không giảm (Bảng III).

Đối chuẩn Thực nghiệm với Cổng Cơ học và Từ chối Ngẫu nhiên: Để kiểm chứng xem quy tắc chọn lọc dựa trên độ tin cậy có thực sự mang lại khả năng phân biệt chẩn đoán vượt trội so với các cơ chế cắt bỏ thô hay không, chúng tôi so sánh đối chuẩn trực tiếp với hai phương pháp cơ sở:



Hình 4. Đường cong đánh đổi rủi ro - độ bao phủ (Risk-Coverage) qua các ngưỡng $\tau \in [0,50; 0,95]$. Selective Stress F_1 nhìn chung tăng còn độ bao phủ giảm khi τ tăng; $\tau = 0,80$ là điểm vận hành minh họa.

1) **Cổng Cơ học (Abstain if Var(ACC) $\geq \theta_{\text{motion}}$):** Theo định nghĩa, cơ chế này từ chối toàn bộ 1.059 cửa sổ có chuyển động mạnh (đạt độ bao phủ 80,0% và hiển nhiên có $\text{FAR}_{\text{motion}} = 0,0\%$). Tuy nhiên, vì pha thuyết trình và tính nhẩm TSST gắn liền với cử động tay, cổng cơ học vứt bỏ một cách mù quáng tới **40,6% các cửa sổ căng thẳng thực sự (764 trên tổng số 1.882 cửa sổ stress)**. Hậu quả là trên tập cửa sổ giữ lại, Stress F_1 sụt giảm nghiêm trọng xuống $84,16\%$ (Macro $F_1 = 89,36\%$). Lưu ý $764/1.059$ (72%) cửa sổ vận động mạnh là cửa sổ stress, phản ánh tương quan giữa vận động và giao thức trong WESAD (Mục VI); đồng thời cổng cơ học giữ 80,0% cửa sổ so với 69,42% của quy tắc đề xuất, nên so sánh cùng độ bao phủ nghiêm ngặt là việc cần làm tiếp.
2) **Từ chối Ngẫu nhiên (Cùng độ bao phủ $= 69,42\%$):** Từ chối ngẫu nhiên 30,58% số cửa sổ đem lại Macro $F_1 = 89,80\% \pm 0,35\%$ và Stress $F_1 = 86,69\% \pm 0,48\%$, trong khi $\text{FAR}_{\text{motion}}$ vẫn ở mức cao $6,78\% \pm 0,82\%$.
3) **Quy tắc Chọn lọc Đề xuất ($\tau = 0,80$):** Khung phương pháp của chúng tôi giữ lại nhiều giai đoạn stress thật trong khi cử động tay, đạt Stress $F_1 = \mathbf{93,15}\%$ và Macro $F_1 = \mathbf{95,20}\%$, đồng thời giảm $\text{FAR}_{\text{motion}}$ $66,6\%$ so với XGBoost thô (từ $12,20\%$ xuống $\mathbf{4,07}\%$) và khoảng 40% so với từ chối ngẫu nhiên cùng độ bao phủ $(6,78\%)$.

Bảng IV và Hình 5 trình bày chi tiết kết quả trên từng đối tượng trong số 15 người tham gia WESAD ($S2 \rightarrow S17$).

Phân tích biến thiên cá nhân trong Bảng IV và Hình 5 cho thấy:

1) Trên **8 trong số 15 folds** (S4, S6, S10, S11, S13, S15, S16, S17), phân loại chọn lọc đạt độ chính xác Stress $F_{1,\text{sel}} = 100,0\%$, và hai fold khác đạt kết quả rất cao (S7: 98,6%, S8: 97,8%).
2) Độ bao phủ trung bình theo đối tượng đạt $69,6\% \pm 22,2\%$ (độ bao phủ gộp là $69,42\%$), dao động từ $14,8\%$ (S10) đến $100,0\%$ (S4), với độ chính xác chọn lọc trung bình $96,1\% \pm 7,1\%$. Sự sụt giảm độ bao phủ mạnh ở S10 $(14,8\%)$ có nghĩa mô hình từ chối 85,2% cửa sổ của đối tượng này; $F_{1,\text{sel}}$ hoàn hảo và $\text{FAR}_{\text{sel}} = 0,0\%$ chỉ tính trên khoảng 54 cửa sổ được giữ lại nên không nên diễn giải quá mức.
3) Tỷ lệ báo động giả khi vận động FAR_{sel} bị triệt tiêu về $0,0\%$ trên **11 trong số 13 đối tượng** có cửa sổ vận động, chỉ còn hai đối tượng còn báo động giả sót lại (S3: 54,5%, S5: 31,6%).
4) Chỉ số trên tập giữ lại có thể che giấu việc bỏ sót ca stress: với S14, độ chính xác trên cửa sổ giữ lại là $96,1\%$ nhưng $F_{1,\text{sel}} = 0,0\%$, và với S2 $F_{1,\text{sel}}$ chỉ $17,6\%$. Do đó F_1 chọn lọc cần được đọc cùng độ bao phủ và độ nhạy (recall) lớp stress.

D. Nghiên cứu Cắt bỏ Đặc trưng Gia tốc (Trả lời RQ4 - Phần 1)

Để kiểm chứng vai trò của cảm biến gia tốc ba trục, chúng tôi tiến hành ablation study qua 5 seed ngẫu nhiên (42, 123, 456, 789, 2024) trên ba cấu hình:

- **Cấu hình A (Chỉ Sinh lý):** 19 đặc trưng (BVP, EDA, TEMP).
- **Cấu hình B (Đầy đủ Bối cảnh):** 25 đặc trưng (Sinh lý + 6 ACC).
- **Cấu hình C (Chỉ Gia tốc):** 6 đặc trưng gia tốc kế.

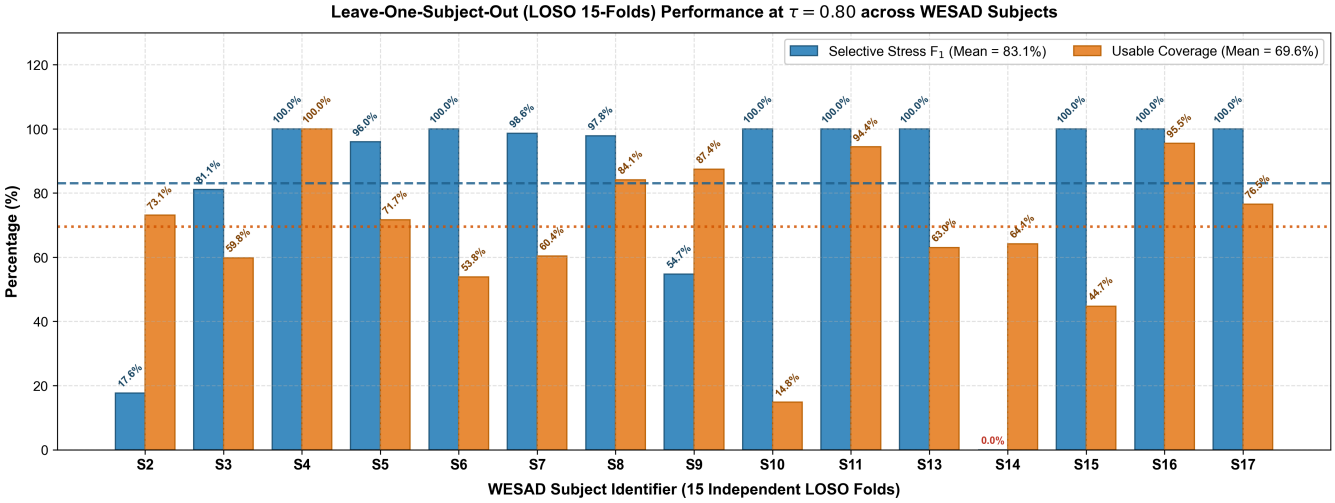
Kết quả trong Bảng V và Hình 6 chỉ ra:

1) **Tính Ổn định Số học Qua các Seeds:** Bổ sung 6 đặc trưng ACC (Cấu hình B) cải thiện số học nhất quán so với chỉ dùng sinh lý (Cấu hình A) qua các seed. Điểm Selective Macro F_1 tăng từ $92,98\% \pm 0,61\%$ lên $94,79\% \pm 0,50\%$ $(+1,81\%)$, trong khi $\text{FAR}^{\text{sel}}_{\text{motion}}$ giảm từ $4,81\% \pm 0,56\%$ xuống $3,46\% \pm 0,65\%$ (giảm $1,35\%$). Ở chế độ full coverage, ACC giúp giảm $\text{FAR}^{\text{full}}_{\text{motion}}$ từ $13,69\%$ xuống $10,44\%$ $(-3,25\%)$. Độ lệch chuẩn trong Bảng V phản ánh biến thiên giữa các seed của bộ học, không phải biến thiên giữa các đối tượng, và các kiểm định theo đối tượng bên dưới cho thấy các chênh lệch này không có ý nghĩa thống kê.
2) **Đánh giá Cấu hình Chỉ Dùng Gia tốc (Cấu hình C):** Cấu hình C (Chỉ dùng ACC) đạt Selective Macro $F_1 = 82,38\% \pm 0,66\%$ (Stress $F_1 = 74,23\% \pm 1,11\%$). Điều này giải thích bởi giao thức WESAD: pha TSST yêu cầu đứng thuyết trình và làm toán nhẩm nên người tham gia cử động tay nhiều hơn hẳn so với lúc ngồi yên đọc sách ở pha baseline. Tuy nhiên, Cấu hình C bị sụt giảm độ bao phủ nghiêm trọng $(45,14\%)$ và có tỷ lệ báo động giả toàn phần rất cao $(\text{FAR}^{\text{full}}_{\text{motion}} = 26,31\%)$, cho thấy gia tốc kế đơn lẻ là không đủ; khả năng phân biệt stress khác không của nó cũng phản ánh tương quan giữa vận động và giao thức (xem Mục VI).
3) **Chi tiết Kiểm định Thống kê và Số Cặp Hiệu dụng:** Kiểm định Wilcoxon signed-rank trên 15 fold (seed 42) ghi nhận: $F_{1,\text{sel}}$ $(W = 9,0, p = 0,753, r_{rb} = 0,143)$, FAR_{sel} $(W = 1,0, p = 1,000, r_{rb} = -0,333)$, và Coverage $(W = 37,0, p = 0,552, r_{rb} = 0,187)$, với $p_{\text{holm}} = 1,000$. Khoảng tin cậy bootstrap cho chênh lệch $(B - A)$ chứa số không: $\Delta F_{1,\text{sel}} = +0,0342$ (95% CI: $[-0,0278; +0,1469]$) và $\Delta\text{FAR}_{\text{sel}} = -1,0169\%$ (95%

Bảng IV

KẾT QUẢ CHI TIẾT TRÊN 15 FOLD LEAVE-ONE-SUBJECT-OUT (LOSO) VỚI MÔ HÌNH XGBOOST HIỆU CHUẨN CHỌN LỌC ($\tau = 0,80$), GẮN NHÃN THEO MÃ ĐỊNH DANH GỐC CỦA WESAD (SUBJECT S14 ĐÁNH GIÁ Ở FOLD 12; SUBJECT S12 BỊ LOẠI BỎ DO LỖI CẢM BIẾN WESAD).

Fold / Đối tượng	Cửa sổ n	Tỷ lệ Stress (%)	Tỷ lệ Vận động (%)	Phán đoán Bắt buộc (Full Coverage)			Phân loại Chọn lọc ($\tau = 0,80$)			
				$F_{1,\text{XGB}}$ (%)	$F_{1,\text{Cal}}$ (%)	FAR_{Cal} (%)	Độ Bao phủ (%)	$F_{1,\text{sel}}$ (%)	$\text{Độ CX}_{\text{sel}}$ (%)	FAR_{sel} (%)
Fold 1 (S2)	338	34,3%	18,9%	76,6%	71,8%	0,0%	73,1%	17,6%	88,7%	0,0%
Fold 2 (S3)	341	35,5%	24,0%	73,1%	71,2%	63,6%	59,8%	81,1%	77,0%	54,5%
Fold 3 (S4)	345	34,8%	15,1%	100,0%	100,0%	0,0%	100,0%	100,0%	100,0%	0,0%
Fold 4 (S5)	353	34,3%	5,4%	89,0%	92,1%	78,9%	71,7%	96,0%	97,6%	31,6%
Fold 5 (S6)	351	35,0%	4,6%	81,7%	94,2%	7.1%	53,8%	100,0%	100,0%	0,0%
Fold 6 (S7)	351	34,5%	17,4%	85,5%	90,6%	–	60,4%	98,6%	98,6%	–
Fold 7 (S8)	352	35,8%	24,7%	91,4%	90,9%	0,0%	84,1%	97,8%	99,0%	0,0%
Fold 8 (S9)	350	34,6%	8,6%	69,19%	64,8%	0,0%	87,4%	54,7%	84,3%	0,0%
Fold 9 (S10)	365	37,5%	16,2%	69,23%	98,6%	0,0%	14,8%	100,0%	100,0%	0,0%
Fold 10 (S11)	357	35,9%	32,2%	98,0%	100,0%	0,0%	94,4%	100,0%	100,0%	0,0%
Fold 11 (S13)	354	35,6%	42,1%	90,0%	89,0%	0,0%	63,0%	100,0%	100,0%	0,0%
Fold 12 (S14)	357	35,9%	20,2%	65,3%	24,7%	–	64,1%	0,0%	96,1%	–
Fold 13 (S15)	358	36,3%	30,4%	89,0%	90,8%	6,8%	44,7%	100,0%	100,0%	0,0%
Fold 14 (S16)	356	35,7%	11,5%	100,0%	100,0%	0,0%	95,5%	100,0%	100,0%	0,0%
Fold 15 (S17)	366	37,4%	28,1%	98,2%	89,3%	30,0%	76,5%	100,0%	100,0%	**0,0%**
Trung bình ± ĐLC	**5294**	**35,5 ± 1,0%**	**20,0 ± 10,5%**	**85,1 ± 12,0%**	**84,5 ± 19,9%**	**14,3 ± 26,8%**	**69,6 ± 22,2%**	**83,1 ± 32,6%**	**96,1 ± 7,1%**	**6,6 ± 16,8%**



Hình 5. Phân phối hiệu năng theo từng đối tượng qua 15 fold LOSO tại $\tau = 0,80$: Điểm Selective Stress $F_{1,\text{sel}}$ (cột xanh) và Độ bao phủ hữu dụng (cột cam) trên từng cá nhân WESAD ($S2 \rightarrow S17$) cùng mức trung bình toàn bộ ($F_{1,\text{sel}} = 83,1\%$, Coverage $= 69,6\%$).

Bảng V

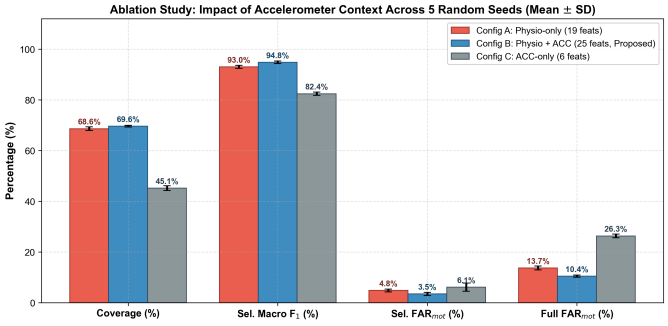
SO SÁNH CẮT BỎ ĐẶC TRƯNG (ABLATION) QUA 5 SEED NGẪU NHIÊN TẠI $\tau = 0,80$ TRÊN WESAD LOSO (TRUNG BÌNH ± ĐỘ LỆCH CHUẨN).

Cấu hình	Độ Bao phủ (%)	Sel. Macro F_1 (%)	$\text{FAR}^{\text{sel}}_{\text{motion}}$ (%)	$\text{FAR}^{\text{full}}_{\text{motion}}$ (%)
A: Chỉ Sinh lý (Không ACC)	$68,60 \pm 0,71$	$92,98 \pm 0,61$	$4,81 \pm 0,56$	$13,69 \pm 0,74$
B: Đầy đủ (+ 6 ACC)	$\mathbf{69,60 \pm 0,33}$	$\mathbf{94,79 \pm 0,50}$	$\mathbf{3,46 \pm 0,65}$	$\mathbf{10,44 \pm 0,44}$
C: Chỉ Gia tốc (ACC)	$45,14 \pm 0,93$	$82,38 \pm 0,66$	$6,10 \pm 1,59$	$26,31 \pm 0,70$

CI: $[-4,5977; +1,0870]$). Lý do $p > 0,05$ là vì trên nhiều đối tượng, cả hai cấu hình đều đạt 0% báo động giả (chỉ có $n_{\text{nonzero}} = 2$ cặp khác biệt cho FAR_{sel} và $n_{\text{nonzero}} = 6$ cho F_1), khiến kiểm định Wilcoxon bị giới hạn về lực thống kê trên mẫu $N = 15$.

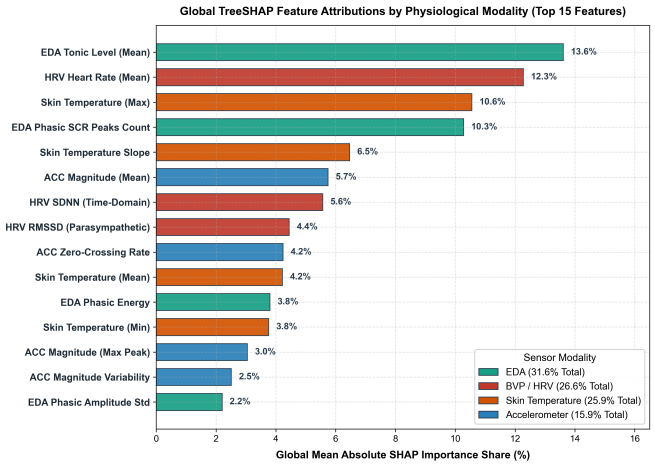
E. Đóng góp Đặc trưng TreeSHAP và Phân tích Ngoại lai (Trả lời RQ4 - Phần 2)

1) Đóng góp Tổng thể theo Cảm biến: Phân tích TreeSHAP [26] trên toàn bộ dự đoán ngoài tập (Hình 7) chỉ ra EDA chiếm $31,6\%$ đóng góp, tiếp theo là BVP/HRV $(26,6\%)$, TEMP $(25,9\%)$, và ACC $(15,9\%)$. Bốn đặc trưng quan trọng nhất là `eda_tonic_mean` (13,6%), `hrv_mean_hr` (12,3%), `temp_max` (10,6%), và `eda_scr_peaks_count` (10,3%); thứ hạng đặc trưng theo từng đối tượng khá ổn định (tương quan Spearman cặp trung bình $0,87$). Bốn đặc trưng phân tán HRV



Hình 6. So sánh ablation đa chỉ số tại $\tau = 0,80$: Về số học, bối cảnh gia tốc đi kèm độ bao phủ nhỉnh hơn và báo động giả khi vận động thấp hơn (chênh lệch không có ý nghĩa thống kê).

(`hrv_sdnn`, `hrv_rmssd`, `hrv_hf`, `hrv_pnn50`) có tương quan dương với nhãn stress (Spearman $\rho \approx +0,46$ đến $+0,54$), ngược chiều rút giảm phó giao cảm kinh điển; điều này có thể phản ánh nhiễu khoảng nhịp do vận động trong BVP cổ tay [46] hoặc hiệu ứng giao thức, nên không nên diễn giải là rút giảm phó giao cảm. Tương tự, `temp_max` (hạng 3) có thể một phần phản ánh thứ tự cố định của các pha giao thức chứ không chỉ co mạch.



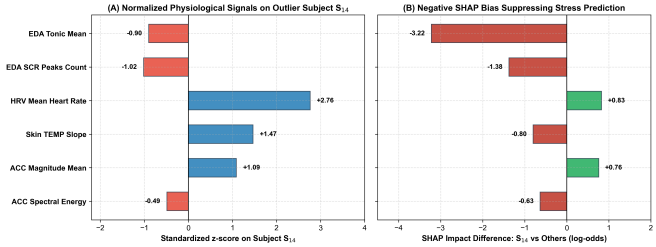
Hình 7. Đóng góp thuộc tính đặc trưng toàn cục TreeSHAP cho mô hình nhận diện stress từ cổ tay.

2) Mẫu hình Xung đột Tín hiệu Kích hoạt Từ chối: Phân tích các cửa sổ bị từ chối (*Bất định*) cho thấy: khi gia tốc ghi nhận rung lắc mạnh trong khi nhịp tim và dẫn truyền da dao động không dứt khoát, sự xung đột này khiến xác suất hậu nghiệm rơi vào vùng lưỡng lự $[1-\tau, \tau]$ và kích hoạt từ chối phán đoán an toàn.

3) Phân ly Sinh lý ở Ca Ngoại lai Subject S14: Hình 8 phân tích trường hợp cá nhân S14 (Fold 12). S14 có các đặc trưng điện da thấp hơn đoàn hệ (z-score $-0,90$ với `eda_tonic_mean` và $-1,02$ với `eda_scr_peaks_count`), phù hợp với nhưng chưa đủ để khẳng định hồ sơ *giảm phản ứng điện da* (electrodermal hypo-responder) [10]; z-score cỡ này chỉ lệch khoảng một độ lệch chuẩn so với đoàn hệ. Trong Hình 8B, khi so sánh đóng góp SHAP với đoàn hệ mẫu, riêng đặc trưng `eda_tonic_mean` tạo ra chênh lệch đóng góp SHAP âm mạnh $(-3,22)$ kéo dự đoán về Không Stress, lấn át tín hiệu nhịp tim nhanh $(z = +2,76)$. Điều này gợi ý vì sao mô hình cây dựa nhiều vào EDA bị suy giảm trên đối tượng này ($F_{1,\text{sel}} = 0,0\%$); Stress F_1 cao hơn của MLP ở độ bao phủ đầy đủ $(97,2\%)$ phù hợp với, nhưng chưa chứng minh, việc khai thác các tổ hợp phi tuyến khác. Đây chỉ là một ca nghiên cứu đơn lẻ. Hiện tượng này nhấn mạnh sự cần thiết của cơ chế thích ứng cá nhân hóa trong các nghiên cứu tiếp theo.

VI. Hạn chế và Cân nhắc Thực tiễn

Mặc dù khung phương pháp đạt được hiệu quả vượt trội trong việc triệt tiêu báo động giả, các hạn chế phương pháp luận sau đây cần được nhìn nhận minh bạch:



Hình 8. Hiện tượng phân ly sinh lý trên ca ngoại lai S14: Phản ứng điện da kém nhạy lấn át tín hiệu nhịp tim nhanh trong pha căng thẳng.

1) **Quy mô Một Bộ Dữ liệu Phòng Thí nghiệm ($N = 15$):** WESAD là tập dữ liệu thu thập trong môi trường phòng lab có kiểm soát với 15 người dưới kích thích giao thức TSST (nghiên cứu này chỉ dùng pha Baseline và TSST Stress). Căng thẳng tâm lý trong đời sống thực phong phú và phức tạp hơn. Việc kiểm chứng mô hình trên các tập dữ liệu tự do ngoài đời thực là bước đi cần thiết tiếp theo.
2) **Mối Tương quan Gắn liền Giao thức Thí nghiệm:** Trong WESAD, pha TSST đòi hỏi người tham gia đứng thuyết trình và làm tính nhẩm trước ban giám khảo, tự nhiên tạo ra nhiều cử động tay hơn so với lúc ngồi đọc sách ở pha baseline. Do đó, gia tốc mang tính tương quan với kịch bản lab. Việc khái quát hóa sang các hoạt động thể thao mạnh đòi hỏi các tập dữ liệu có bài tập thể chất riêng biệt.
3) **Ngưỡng Tin cậy Vận hành vs Ngưỡng Thích ứng:** Mặc dù $\tau = 0,80$ đem lại điểm cân bằng vận hành hiệu quả trên dữ liệu gộp, độ bao phủ thực tế trên từng người dao động từ 14,8% (S10) đến 100,0% (S4). Độ bao phủ thấp cục bộ cho thấy một ngưỡng tĩnh có thể quá khắt khe với một số cá nhân, gợi mở hướng phát triển ngưỡng thích ứng động theo cơ địa sinh lý của từng người.
4) **Độ Phức tạp Tính toán Trích xuất Đặc trưng Nhúng:** Mặc dù suy luận của cây quyết định được kỳ vọng là rất nhẹ (chưa đo độ trễ trong nghiên cứu này), khâu trích xuất đặc trưng sinh lý—đặc biệt là lọc số tách sóng EDA và biến đổi FFT cho HRV—đòi hỏi tài nguyên tính toán đáng kể trên vi điều khiển năng lượng siêu thấp. Các thuật toán xấp xỉ số nguyên nhẹ là hướng tối ưu hóa phần cứng quan trọng trong tương lai.
5) **Phạm vi Thống kê:** Trừ MLP và ablation (5 seed), kết quả dùng một seed; chưa có khoảng tin cậy cho $\text{FAR}_{\text{motion}}$, vốn có mẫu số 295 cửa sổ từ 13 đối tượng và bị chi phối bởi một vài đối tượng; các chênh lệch trong ablation gia tốc và giữa MLP–XGBoost không có ý nghĩa thống kê.
6) **Hiệu chuẩn và Chọn Ngưỡng:** Hiệu chuẩn Isotonic không làm giảm ECE ở độ bao phủ đầy đủ của XGBoost $(0,0612 \rightarrow 0,0744)$; ECE $0,0290$ chỉ đo trên các dự đoán được giữ lại có độ tin cậy cao, và $\tau = 0,80$ là điểm vận hành minh họa cố định chứ không phải ngưỡng đã tối ưu.
7) **Định nghĩa Lớp Không Stress:** Lớp Không Stress là trạng thái Baseline ngồi nghỉ, nên $\text{FAR}_{\text{motion}}$ phản ánh cử

động tay khi ngồi nghỉ chứ không phải đi bộ hay tập thể dục.

VII. Kết luận

Nghiên cứu này đã so sánh một cách hệ thống giữa bài toán nhận diện căng thẳng bắt buộc 100% và cơ chế phân loại chọn lọc có từ chối trên thiết bị đeo cổ tay. Qua khảo sát tám kiến trúc học máy dưới giao thức 15-fold LOSO trên WESAD, ghi nhận tỷ lệ báo động giả cao trên các cửa sổ vận động ở mọi họ mô hình dưới chế độ ép buộc phán đoán ($\mathrm{FAR}_{\mathrm{motion}} \approx 12,2\% - 24,0\%$), trong khi phân loại chọn lọc triệt tiêu từ 55,0% đến 90,0% các cảnh báo sai này. Hệ thống đề xuất đạt các chỉ số độ tin cậy tốt (Selective Macro $F_1 = 95,20\%$, ECE $= 0,0290$ trên tập giữ lại, $\mathrm{FAR}_{\mathrm{motion}} = 4,07\%$) tại độ bao phủ vận hành $69,42\%$. Với khả năng giải thích TreeSHAP và đánh giá trên 15 đối tượng (một tập lab nhỏ; chênh lệch do gia tốc và giữa MLP–XGBoost chưa có ý nghĩa thống kê), công trình đặt ra các nguyên lý thiết kế thực tiễn cho các hệ thống giám sát sức khỏe đeo tay đáng tin cậy.

Tài liệu

[1] S. Cohen, D. Janicki-Deverts, and G. E. Miller, "Psychological stress and disease," *JAMA*, vol. 298, no. 14, pp. 1685–1687, 2007.

[2] N. Schneiderman, G. Ironson, and S. D. Siegel, "Stress and health: Psychological, behavioral, and biological determinants," *Annu. Rev. Clin. Psychol.*, vol. 1, pp. 607–628, 2005.

[3] Y. S. Can, B. Arnrich, and C. Ersoy, "Stress detection in daily life scenarios using smart phones and wearable devices: A review," *J. Biomed. Inform.*, vol. 92, p. 103139, 2019.

[4] M. Gjoreski, H. Gjoreski, M. Luštrek, and M. Gams, "Continuous stress detection using a wrist device: In laboratory and real life," in *Proc. ACM Int. Joint Conf. Pervasive Ubiquitous Comput. (UbiComp Adjunct)*, 2016, pp. 1185–1193.

[5] P. Schmidt, A. Reiss, R. Duerichen, C. Marberger, and K. Van Laerhoven, "Introducing WESAD, a multimodal dataset for wearable stress and affect detection," in *Proc. 20th ACM Int. Conf. Multimodal Interaction (ICMI)*, 2018, pp. 400–408.

[6] A. Sano, A. J. Phillips, A. Z. Yu, A. W. McHill, S. Taylor, N. Jaques, C. A. Czeisler, E. B. Klerman, and R. W. Picard, "Recognizing academic performance, sleep quality, stress level, and mental health using personality traits, wearable sensors and mobile phones," in *Proc. IEEE 12th Int. Conf. Wearable Implantable Body Sensor Netw. (BSN)*, 2015, pp. 1–6.

[7] J. Schumm, M. Bächlin, C. Setz, B. Arnrich, D. Roggen, and G. Tröster, "Effect of movement on the electrodermal response after a startle event," *Methods Inf. Med.*, vol. 47, no. 3, pp. 186–191, 2008.

[8] T. Tamura, Y. Maeda, M. Sekine, and M. Yoshida, "Wearable photoplethysmographic sensors—past and present," *Electronics*, vol. 3, no. 2, pp. 282–302, 2014.

[9] Z. Zhang, Z. Pi, and B. Liu, "TROIKA: A general framework for heart rate monitoring using wrist-type photoplethysmographic signals during intensive physical exercise," *IEEE Trans. Biomed. Eng.*, vol. 62, no. 2, pp. 522–531, 2015.

[10] W. Boucsein, *Electrodermal Activity*, 2nd ed. New York, NY, USA: Springer Science & Business Media, 2012.

[11] P. Siirtola, "Continuous stress detection using the sensors of commercial smartwatch," in *Proc. ACM Int. Joint Conf. Pervasive Ubiquitous Comput. (UbiComp/ISWC Adjunct)*, 2019, pp. 1198–1201.

[12] P. Bobade and M. Vani, "Stress detection with machine learning and deep learning using multimodal physiological data," in *Proc. 2nd Int. Conf. Inventive Research in Computing Applications (ICIRCA)*, 2020, pp. 51–57.

[13] K. M. Dalmeida and G. L. Masala, "HRV features as viable physiological markers for stress detection using wearable devices," *Sensors*, vol. 21, no. 8, p. 2873, 2021.

[14] B. Behinaein, A. Bhatti, D. Rodenburg, P. Hungler, and A. Etemad, "A transformer architecture for stress detection from ECG," in *Proc. ACM Int. Symp. Wearable Comput. (ISWC)*, 2021, pp. 132–134.

[15] R. Castaldo, P. Melillo, U. Bracale, M. Caserta, M. Triassi, and L. Pecchia, "Acute mental stress assessment via short term HRV analysis in healthy adults: A systematic review with meta-analysis," *Biomed. Signal Process. Control*, vol. 18, pp. 370–377, 2015.

[16] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proc. 34th Int. Conf. Machine Learning (ICML)*, 2017, pp. 1321–1330.

[17] S. Sendelbach and M. Funk, "Alarm fatigue: A patient safety concern," *AACN Adv. Crit. Care*, vol. 24, no. 4, pp. 378–386, 2013.

[18] C. K. Chow, "On optimum recognition error and reject tradeoff," *IEEE Trans. Inf. Theory*, vol. 16, no. 1, pp. 41–46, 1970.

[19] C. Cortes, G. DeSalvo, and M. Mohri, "Learning with rejection," in *Proc. Int. Conf. Algorithmic Learning Theory (ALT)*, 2016, pp. 67–82.

[20] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 4878–4887.

[21] Y. Geifman and R. El-Yaniv, "SelectiveNet: A deep neural network with an integrated reject option," in *Proc. 36th Int. Conf. Machine Learning (ICML)*, 2019, pp. 2151–2159.

[22] Y. Grandvalet, A. Rakotomamonjy, J. Keshet, and S. Canu, "Support vector machines with a reject option," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 21, 2008, pp. 537–544.

[23] K. Hendrickx, L. Perini, D. Van der Plas, W. Meert, and J. Davis, "Machine learning with a reject option: A survey," *Mach. Learn.*, vol. 113, no. 5, pp. 3073–3110, 2024.

[24] S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "The need to approximate the use-case in clinical machine learning," *GigaScience*, vol. 6, no. 5, p. gix019, 2017.

[25] M. A. Little, G. Varoquaux, S. Saeb, L. Lonini, A. Jayaraman, D. C. Mohr, and K. P. Kording, "Using and understanding cross-validation strategies: Perspectives on Saeb et al.," *GigaScience*, vol. 6, no. 5, p. gix020, 2017.

[26] S. M. Lundberg, G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee, "From local explanations to global understanding with explainable AI for trees," *Nature Machine Intelligence*, vol. 2, no. 1, pp. 56–67, 2020.

[27] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, "Heart rate variability: Standards of measurement, physiological interpretation, and clinical use," *Circulation*, vol. 93, no. 5, pp. 1043–1065, 1996.

[28] M. Garbarino, M. Lai, D. Bender, R. W. Picard, and S. Tognetti, "Empatica E3—A wearable wireless multi-sensor device for real-time computerized biofeedback and data acquisition," in *Proc. 4th Int. Conf. Wirel. Mobile Commun. Healthc. (MobiHealth)*, 2014, pp. 39–42.

[29] J. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," *Adv. Large Margin Classif.*, vol. 10, no. 3, pp. 61–74, 1999.

[30] M. Kull, T. Silva Filho, and P. Flach, "Beta calibration: a well-founded and easily implemented alternative to logistic calibration for binary classifiers," in *Proc. 20th Int. Conf. Artif. Intell. Stat. (AISTATS)*, 2017, pp. 623–631.

[31] B. Zadrozny and C. Elkan, "Transforming classifier scores into accurate multiclass probability estimates," in *Proc. 8th ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD)*, 2002, pp. 694–699.

[32] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proc. 22nd Int. Conf. Machine Learning (ICML)*, 2005, pp. 625–632.

[33] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD)*, 2016, pp. 785–794.

[34] R. Shwartz-Ziv and R. Armon, "Tabular data: Deep learning is not all you need," *Inf. Fusion*, vol. 81, pp. 84–90, 2022.

[35] L. Grinsztajn, E. Oyallon, and G. Varoquaux, "Why do tree-based models still outperform deep learning on typical tabular data?," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 35, 2022, pp. 507–520.

[36] V. Borisov, T. Leemann, K. Seßler, J. Haug, M. Pawelczyk, and G. Kasneci, "Deep neural networks and tabular data: A survey," *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 35, no. 6, pp. 7499–7519, 2024.

[37] D. Makowski, T. Pham, Z. J. Lau, J. C. Brammer, F. Lespinasse, H. Pham, C. Schölzel, and S. H. A. Chen, "NeuroKit2: An open-source Python toolbox for neurophysiological signal processing," *Behav. Res. Methods*, vol. 53, no. 4, pp. 1689–1696, 2021.

[38] M. P. Tarvainen, J.-P. Niskanen, J. A. Lipponen, P. O. Ranta-Aho, and P. A. Karjalainen, "Kubios HRV–heart rate variability analysis software," *Comput. Methods Programs Biomed.*, vol. 113, no. 1, pp. 210–220, 2014.

[39] R. El-Yaniv and Y. Wiener, "On the foundations of noise-free selective classification," *J. Mach. Learn. Res.*, vol. 11, pp. 1605–1641, 2010.

[40] M. P. Naeini, G. Cooper, and M. Hauskrecht, "Obtaining well calibrated probabilities using Bayesian binning," in *Proc. 29th AAAI Conf. Artif. Intell.*, 2015, pp. 2901–2907.

[41] M. Gjoreski, M. Luštrek, M. Gams, and H. Gjoreski, "Monitoring stress with a wrist device using context," *J. Biomed. Inform.*, vol. 73, pp. 159–170, 2017.

[42] C. McCarthy, N. Pradhan, C. Redpath, and A. Adler, "Validation of the Empatica E4 wristband," in *Proc. IEEE EMBS Int. Student Conf. (ISC)*, 2016, pp. 1–4.

[43] S. Taylor, N. Jaques, W. Chen, S. Fedor, A. Sano, and R. Picard, "Automatic identification of artifacts in electrodermal activity data," in *Proc. 37th Annu. Int. Conf. IEEE Eng. Med. Biol. Soc. (EMBC)*, 2015, pp. 1934–1937.

[44] I. R. Kleckner *et al.*, "Simple, transparent, and flexible automated quality assessment procedures for ambulatory electrodermal activity data," *IEEE Trans. Biomed. Eng.*, vol. 65, no. 7, pp. 1460–1467, 2018.

[45] M. Elgendi, "Optimal signal quality index for photoplethysmogram signals," *Bioengineering*, vol. 3, no. 4, p. 21, 2016.

[46] A. Schäfer and J. Vagedes, "How accurate is pulse rate variability as an estimate of heart rate variability?" *Int. J. Cardiol.*, vol. 166, no. 1, pp. 15–29, 2013.

[47] L. Pecchia, R. Castaldo, L. Montesinos, and P. Melillo, "Are ultra-short heart rate variability features good surrogates of short-term ones? State-of-the-art review and recommendations," *Healthc. Technol. Lett.*, vol. 5, no. 3, pp. 94–100, 2018.

[48] M. L. Munoz *et al.*, "Validity of (ultra-)short recordings for heart rate variability measurements," *PLoS ONE*, vol. 10, no. 9, p. e0138921, 2015.

[49] P. D. Welch, "The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms," *IEEE Trans. Audio Electroacoust.*, vol. 15, no. 2, pp. 70–73, 1967.

[50] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bull.*, vol. 1, no. 6, pp. 80–83, 1945.

[51] S. Holm, "A simple sequentially rejective multiple test procedure," *Scand. J. Stat.*, vol. 6, no. 2, pp. 65–70, 1979.

[52] J. Demšar, "Statistical comparisons of classifiers over multiple data sets," *J. Mach. Learn. Res.*, vol. 7, pp. 1–30, 2006.

[53] D. S. Kerby, "The simple difference formula: An approach to teaching nonparametric correlation," *Compr. Psychol.*, vol. 3, art. 11.IT.3.1, 2014.

[54] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.

[55] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *J. Mach. Learn. Res.*, vol. 12, pp. 2825–2830, 2011.

[56] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017, pp. 3146–3154.

[57] L. Breiman, "Random forests," *Mach. Learn.*, vol. 45, no. 1, pp. 5–32, 2001.

[58] Y. Freund and R. E. Schapire, "A decision-theoretic generalization of on-line learning and an application to boosting," *J. Comput. Syst. Sci.*, vol. 55, no. 1, pp. 119–139, 1997.

[59] L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone, *Classification and Regression Trees*. Belmont, CA, USA: Wadsworth, 1984.

[60] T. Cover and P. Hart, "Nearest neighbor pattern classification," *IEEE Trans. Inf. Theory*, vol. 13, no. 1, pp. 21–27, 1967.

[61] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," in *Proc. 3rd Int. Conf. Learn. Represent. (ICLR)*, 2015.